

# Documentação Técnica do Desafio LH Nautical

**Autora:** Daiane das Graças Barbosa Koslowski

**Data:** 16 Agosto de 2026

**Banco de Dados:** PostgreSQL (Neon Cloud)

**Aplicação Web:** Streamlit hospedado no Render

## Contexto do Desafio e Objetivos do Projeto

A **LH Nautical** é uma varejista do setor náutico que opera lojas físicas (POS), armazéns e e-commerce. Esta documentação detalha a arquitetura do pipeline de dados, a modelagem relacional dos 24 arquivos CSV operacionais, as análises de negócio solicitadas pelos stakeholders (Gabriel Santos, Marina Costa e Sr. Almir), além dos modelos preditivos e de recomendação desenvolvidos.

## 1. Análise Exploratória de Dados (EDA) & Validação de Qualidade

Diagnóstico da Tabela `orders`

**Volume de Dados:** 48.998 linhas e 13 colunas.

**Janela Temporal:** 01/01/2020 a 01/01/2027.

**Métricas Financeiras (`total`):**

- Valor Mínimo: R\$ 32,62
- Valor Máximo: R\$ 127.262,02
- Valor Médio: R\$ 28.704,99

Diagnóstico de Confiabilidade

**Outliers:**

A grande diferença entre o menor e o maior valor não indica necessariamente um erro nos dados. Ela pode ser explicada pela variedade do catálogo náutico, que reúne tanto produtos de alto valor, como motores de popa e embarcações, quanto peças e acessórios mais baratos.

**Valores nulos e inconsistências:**

As principais colunas da tabela apresentam boa qualidade, sem valores nulos em id, customer\_id, created\_at e total. Já a coluna salesperson\_id possui aproximadamente 49,2% de registros nulos. Esse resultado parece coerente com a operação da empresa, pois os pedidos feitos pelo e-commerce normalmente não estão vinculados a um vendedor específico.

**Prontidão para análise:**

A tabela possui uma boa estrutura inicial, mas ainda precisa de alguns tratamentos antes de ser utilizada em dashboards gerenciais. É necessário revisar a tipagem dos campos no banco de dados, filtrar os pedidos conforme seus status e relacionar a tabela com outras fontes, como itens, clientes e canais de venda. Dessa forma, as análises poderão refletir com mais precisão as transações válidas da empresa.

## 2. Engenharia de Dados: Inferência de Schema e Carga no PostgreSQL

### 2.1 Gerador Automático de DDL (`gerar_schema.py`)

Para cumprir a premissa de utilizar estritamente a biblioteca padrão do Python 3 (sem bibliotecas de terceiros como Pandas), desenvolveu-se um algoritmo nativo (`csv`, `os`). O script lê as primeiras 200 linhas de cada um dos 24 arquivos CSV para inferir tipos de dados no padrão PostgreSQL (`BIGINT`, `NUMERIC`, `TIMESTAMP`, `DATE`, `BOOLEAN`, `VARCHAR`) e gera o arquivo `schema.sql`.

### 2.2 Pipeline de Ingestão (`carregar_dados.py`)

A carga dos dados no PostgreSQL (Neon DB) é executada via instrução nativa `COPY` utilizando `psycopg2.copy_expert`, permitindo a inserção de alta performance sem alterar a estrutura original.

#### Validação de Linhas Carregadas:

- `customers`: 2.000 linhas
- `orders`: 48.998 linhas
- `order_items`: 147.320 linhas
- `payments`: 53.546 linhas

**Total Agregado de Teste:** 251.864 linhas

## 3. Análise de Negócios & Consultas SQL

### 3.1 Identificação dos Clientes "Elite / Fiéis"

Para atuar na estratégia solicitada pela Gerente de Negócios (Marina Costa), foram mapeados os clientes com maior Ticket Médio que atendem ao critério de diversidade mínima de compra em no mínimo 13 categorias distintas de produtos.

```
WITH metricas_pedidos AS (  
  SELECT  
    customer_id,  
    SUM(total) AS faturamento_total,  
    COUNT(id) AS frequencia,  
    SUM(total) / COUNT(id) AS ticket_medio  
  FROM orders  
  GROUP BY customer_id  
)  
diversidade_cliente AS (  
  SELECT  
    o.customer_id,  
    COUNT(DISTINCT p.category_id) AS diversidade_categorias
```

```

FROM orders o
JOIN order_items oi ON o.id = oi.order_id
JOIN product_variants pv ON oi.product_variant_id = pv.id
JOIN products p ON pv.product_id = p.id
GROUP BY o.customer_id
),
top_10_clientes AS (
  SELECT
    m.customer_id,
    m.faturamento_total,
    m.frequencia,
    m.ticket_medio,
    d.diversidade_categorias
  FROM metricas_pedidos m
  JOIN diversidade_cliente d ON m.customer_id = d.customer_id
  WHERE d.diversidade_categorias >= 13
  ORDER BY m.ticket_medio DESC, m.customer_id ASC
  LIMIT 10
)
SELECT * FROM top_10_clientes;

```

### 3.2 Dimensão de Calendário e Correção do Viés de Vendas em Lojas Físicas

Para responder ao Sr. Almir sobre o desempenho das lojas físicas (POS) sem distorções, construiu-se uma Dimensão de Datas contínua usando `generate_series()`. A junção via `LEFT JOIN` com a tabela de vendas trata dias sem movimento através de `COALESCE(..., 0)`, garantindo que dias com venda zero façam parte do divisor da média.

```

WITH calendario AS (
  SELECT generate_series(
    (SELECT MIN(created_at::date) FROM orders),
    (SELECT MAX(created_at::date) FROM orders),
    '1 day'::interval
  )::date AS data
),
vendas_diarias AS (
  SELECT
    created_at::date AS data,
    SUM(total) AS faturamento_dia
  FROM orders
  WHERE LOWER(channel) = 'pos'
  GROUP BY created_at::date
),
vendas_completas AS (

```

```

SELECT
  c.data,
  EXTRACT(DOW FROM c.data) AS ordem_dia,
  CASE EXTRACT(DOW FROM c.data)
    WHEN 0 THEN 'Domingo'
    WHEN 1 THEN 'Segunda-feira'
    WHEN 2 THEN 'Terça-feira'
    WHEN 3 THEN 'Quarta-feira'
    WHEN 4 THEN 'Quinta-feira'
    WHEN 5 THEN 'Sexta-feira'
    WHEN 6 THEN 'Sábado'
  END AS dia_semana,
  COALESCE(v.faturamento_dia, 0) AS faturamento_dia
FROM calendario c
LEFT JOIN vendas_diarias v ON c.data = v.data
)
SELECT
  dia_semana,
  ROUND(AVG(faturamento_dia), 2) AS media_vendas
FROM vendas_completas
GROUP BY ordem_dia, dia_semana
ORDER BY media_vendas ASC;

```

## 4. Ciência de Dados e Modelagem Preditiva

### 4.1 Previsão de Demanda "Bússola de Bordo 702"

- **Objetivo:** Prever a demanda mensal do produto no primeiro trimestre de 2026 (Q1 2026)
- **Período de Treino:** Histórico até 31/12/2025
- **Modelo Baseline:** Média Móvel Simples dos últimos 3 meses:
- **Prevenção de Data Leakage:** A previsão para qualquer mês baseou-se exclusivamente nos valores reais dos meses anteriores

$$M_t = \frac{V_{t-1} + V_{t-2} + V_{t-3}}{3}$$

$$\mathcal{J}_{t-1} = \{V_i \mid i \leq t-1\}$$

Métricas e Avaliação (Q1 2026)

- **Soma Exata das Previsões Mensais:** 292,67 unidades
- **Soma Total Arredondada (Inteiro):** 293 unidades
- **Erro Médio Absoluto (MAE):** 29,22

Diagnóstico Crítico do Modelo

O modelo baseline não é adequado para o produto. A série temporal apresenta forte sazonalidade de verão (com picos acentuados de vendas entre Novembro e Janeiro). Por atuar com efeito de atraso (lag), a média móvel subestimou a demanda de Janeiro/2026 (previu 80,33 unidades contra 152 vendas reais), gerando risco severo de ruptura de estoque.

## 4.2 Motor de Recomendação Item-Based Collaborative Filtering

Desenvolvido para criar a vitrine "*Quem comprou isso, também levou...*" direcionada ao item "**Motor de Popa 1949**".

- **Metodologia:** Construção de uma matriz binária Usuário  $\times$  Produto processada via **Similaridade de Cosseno**:
- $$\text{Similaridade}(A, B) = \frac{A \cdot B}{\sqrt{|A|^2 \cdot |B|^2}} = \frac{|C_A \cap C_B|}{\sqrt{|C_A| \cdot |C_B|}}$$
- **Produto Recomendado com Maior Similaridade: Motor de Popa 5331** (Similaridade de Cosseno: **0,2566**).
- **Limitação Técnica:** Suscetível ao problema de Cold Start (Início Frio) e à esparsidade da matriz, onde produtos recentes ou pouco vendidos resultam em vetores nulos e não recebem recomendações.

## 5. Dashboard Interativo & Visualização de Dados

Para comunicar os resultados aos stakeholders (Sr. Almir, Marina Costa e Gabriel Santos), foi desenvolvido um painel interativo em Streamlit, hospedado no Render e conectado diretamente ao banco de dados PostgreSQL (Neon DB).

### 5.1 Visuais e Módulos do Painel

**Visão Geral de Vendas (EDA):** Filtros dinâmicos por canal de venda (POS vs. E-commerce) e acompanhamento do faturamento histórico.

**Análise de Clientes de Elite (Q4):** Tabela e gráfico interativo apresentando os 10 clientes com maior ticket médio (diversidade  $\geq 13$  categorias).

**Média de Vendas por Dia da Semana (Q5):** Gráfico comparativo demonstrando a correção do viés entre a média direta e a média real ajustada via Dimensão de Calendário.

**Previsão de Demanda (Q6):** Gráfico de linha comparando as vendas reais da Bússola de Bordo 702 contra a projeção da Média Móvel de 3 Meses para o Q1 2026, destacando o erro absoluto (MAE).

**Motor de Recomendação (Q7):** Vitrine interativa *Quem comprou isso, também levou...* que gera o ranking do Top 5 produtos similares em tempo real.

## 6. Avaliação Geral do Desafio

### Parte mais fácil

As questões 1, relacionada à análise exploratória dos dados (EDA), e 3, sobre o carregamento das informações, foram as que apresentaram menos dificuldade. Como os arquivos CSV estavam bem estruturados, foi possível validar rapidamente o volume total de 251.864 linhas. Além disso, o uso do comando nativo COPY, do PostgreSQL, tornou o carregamento mais rápido e ajudou a preservar a tipagem dos dados.

### Parte que trouxe maior satisfação técnica

A questão 5, sobre a criação da dimensão de calendário, foi especialmente interessante porque resolveu um problema comum nas análises de negócio: os dias em que a loja estava aberta, mas não realizou nenhuma venda. Considerar esses dias foi importante para evitar distorções nos indicadores apresentados à diretoria.

A questão 7, sobre o sistema de recomendação, também foi bastante satisfatória. Foi uma oportunidade de desenvolver um motor de recomendação utilizando matemática vetorial e álgebra linear em Python, sem depender de bibliotecas externas ou soluções excessivamente complexas.

## 7. Recomendações Estratégicas para Stakeholders

Sr. Almir — Fundador

### **Confiabilidade dos dados:**

Os dados extraídos do ERP apresentam uma boa estrutura, sem valores nulos nas principais chaves dos pedidos. Ainda assim, é importante utilizar uma dimensão de calendário para que os dias em que as lojas estiveram abertas, mas não realizaram vendas, também sejam considerados. Isso evita interpretações equivocadas sobre o faturamento diário.

### **Gestão de estoque:**

As decisões de compra não devem se basear apenas na média simples das vendas anteriores. Produtos sazonais, como coletes e bússolas, precisam ser planejados com base em modelos que considerem períodos de maior e menor demanda. Isso ajuda a reduzir o risco de falta de produtos e de excesso de estoque.

Marina Costa Gerente de Negócios

### **Programa de fidelidade:**

Recomenda-se criar campanhas personalizadas para os 10 clientes que compraram produtos de pelo menos 13 categorias diferentes. Esses clientes demonstram maior variedade de interesse e podem receber ofertas de itens complementares ou benefícios exclusivos.

### **Vendas adicionais no e-commerce:**

Também seria interessante incluir uma vitrine de recomendações no checkout do site. Ao vender o

Motor de Popa 1949, por exemplo, o sistema poderia sugerir o Motor de Popa 5331 e outros produtos relacionados, aumentando as chances de vendas complementares.

Gabriel Santos Tech Lead

### **Evolução do modelo:**

O modelo inicial baseado em Média Móvel Simples pode ser substituído por técnicas capazes de identificar sazonalidade e tendências, como SARIMA, XGBoost ou Prophet. Essa evolução tende a tornar as previsões de demanda mais precisas.

### **Automação do pipeline:**

Os scripts de extração e carregamento, como o `carregar_dados.py`, devem continuar integrados a uma ferramenta de automação, como o `n8n`. Dessa forma, as tabelas do Neon DB poderão ser atualizadas periodicamente, reduzindo tarefas manuais e mantendo os dados disponíveis para as análises.

Link do repositório no GitHub com todos os arquivos oficiais, documentação e dashboard:

<https://github.com/DaihSeven/Project-Azimuth.git>

\* **Curiosidade sobre o nome do projeto Project Azimuth:** Azimute é a coordenada usada na navegação astronômica para medir direções. E este projeto significa para uma empresa uma forma de direcionar melhor suas informações, dados e recursos.